Πολυτεχνείο Κρήτης
Σχολή ΗΜΜΥ
Στατιστική Μοντελοποίηση και Αναγνώριση Προτύπων
Παράδοση 1ης εργασίας
Ημερομηνία Παράδοσης: 27 Απριλίου 2023

Ομάδα 33

	Φοιτητής 1	Φοιτητής 2
Επώνυμο	Αντωνογιαννάκης	Χαϊντούτη
Όνομα	Ιωάννης	Μαρία
Α.Μ.	2020030018	2020030129

Θέμα 1:Bayes.

a. Για να βρούμε το βέλτιστο σύνορο απόφασης (διαχωρισμού) πρέπει να ελαχιστοποιήσουμε την πιθανότητα λάθους:

$Perr = P(\omega_1)P(\omega_2|\omega_1) + P(\omega_2)P(\omega_1|\omega_2) = P(\omega_1)(1 - P(x \in R_1|\omega_2)) + P(\omega_2)P(x \in R_1|\omega_2) = P(\omega_1) - P(\omega_1)P(x \in R_1|\omega_1) + P(\omega_2)P(x \in R_1|\omega_2) = P(\omega_1) - P(\omega_1)\int_{R_1} f_{x|\omega_1}(y)dy + P(\omega_2)\int_{R_1} f_{x|\omega_2}(y)dy = P(\omega_1) + \int_{R1}(P(\omega_2)f_{x|\omega_2}(y) - P(\omega_1)(f_{x|\omega_1}(y))dy = P(\omega_1) + \int_{R1} f_x(y)(P(\omega_2|x=y) - P(\omega_1|x=y))dy$

Τα $P(\omega_1), P(\omega_2), f_x(y), P(\omega_1|x=y), P(\omega_2|x=y)$ δεν αλλάζουν, οπότε, για να ελαχιστοποιηθεί το σφάλμα πρέπει να διαμορφώσουμε την R_1. Συνεπώς, ο κανόνας απόφασης θα είναι: $P(\omega_2|x=y) \gtrless P(\omega_1|x=y)$ (1). Μέσω του θεωρήματος Bayes η ανισότητα (1) γίνεται:

$\frac{P(\omega_2)f_{(x|\omega_2)}(y)}{f_x(y)} \gtrless \frac{P(\omega_1)f_{(x|\omega_1)}(y)}{f_x(y)} \Rightarrow P(\omega_2)f_{(x|\omega_2)}(y) \gtrless P(\omega_1)f_{(x|\omega_1)}(y) \Rightarrow$

$\Rightarrow P(\omega_2)\frac{1}{(2\pi|\Sigma_1|)^{1/2}}\exp(-\frac{1}{2}(x-\mu_2)^T\Sigma_2^{-1}(x-\mu_2))] \gtrless P(\omega_1)\frac{1}{(2\pi|\Sigma_2|)^{1/2}}\exp(-\frac{1}{2}(x-\mu_1)^T\Sigma_1^{-1}(x-\mu_1))] \Rightarrow P(\omega_2)(\frac{1}{(2\pi)^2|\Sigma_1|)^{1/2}})\, e^{-(1/2)(x-\mu_2)^T\Sigma_2^{-1}(x-\mu_2)} \gtrless P(\omega_1)\,(\frac{1}{(2\pi)^2|\Sigma_2|)^{1/2}})\, e^{-(1/2)(x-\mu_1)^T\Sigma_1^{-1}(x-\mu_1)} \Rightarrow$

$\ln(\frac{P(\omega_2)}{P(\omega_1)}) + \frac{1}{2}(-x^T\Sigma_2^{-1}x + x^T\Sigma_2^{-1}\mu_2 - \mu_2^T\Sigma_2^{-1}\mu_2 + \mu_2^T\Sigma_2^{-1}x + x^T\Sigma_1^{-1}x - x\Sigma_1^{-1}\mu_1 - \mu_1\Sigma_1^{-1}x + \mu_1^T\Sigma_1^{-1}\mu_1) \gtrless 0$ (2)

Παρακάτω παρατίθενται τα αποτελέσματα των στοιχείων:

- $\Sigma_2^{-1} = \frac{1}{(1.2^2-(-0.4)^2)}\begin{bmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{bmatrix} = \frac{1}{1.28}\begin{bmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{bmatrix}$
- $\Sigma_1^{-1} = \frac{1}{(1.2^2-(0.4)^2)}\begin{bmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{bmatrix} = \frac{1}{1.28}\begin{bmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{bmatrix}$
- $x^T\Sigma_2^{-1}x = \begin{bmatrix} a & b \end{bmatrix}\left(\frac{1}{1.28}\right)\begin{bmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{bmatrix}\begin{bmatrix} a \\ b \end{bmatrix} = \frac{1}{1.28}(1.2(a^2+b^2) - 0.8ab)$
- $x^T\Sigma_1^{-1}x = \begin{bmatrix} a & b \end{bmatrix}\left(\frac{1}{1.28}\right)\begin{bmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{bmatrix}\begin{bmatrix} a \\ b \end{bmatrix} = \frac{1}{1.28}(1.2(a^2+b^2) + 0.8ab)$
- Αρα: $-x^T\Sigma_1^{-1}x + x^T\Sigma_2^{-1}x = -1.25ab$
- $\mu_2^T\Sigma_2^{-1}\mu_2 = \frac{1}{1.28}\begin{bmatrix} 6 & 6 \end{bmatrix}\begin{bmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{bmatrix}\begin{bmatrix} 6 \\ 6 \end{bmatrix} = 45$

- $\mu_1^T \Sigma_1^{-1} \mu_1 = \frac{1}{1.28} \begin{bmatrix} 3 & 3 \end{bmatrix} \begin{bmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{bmatrix} \begin{bmatrix} 3 \\ 3 \end{bmatrix} = 22.5$
- Αρα: $\mu_2^T \Sigma_2^{-1} \mu_2 - \mu_1^T \Sigma_1^{-1} \mu_1 = -22.5$
- $x^T \Sigma_2^{-1} \mu_2 = \frac{1}{1.28} \begin{bmatrix} a & b \end{bmatrix} \begin{bmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{bmatrix} \begin{bmatrix} 6 \\ 6 \end{bmatrix} = 3.75(a+b)$
- $x^T \Sigma_1^{-1} \mu_1 = \frac{1}{1.28} \begin{bmatrix} a & b \end{bmatrix} \begin{bmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{bmatrix} \begin{bmatrix} 3 \\ 3 \end{bmatrix} = 3.75(a+b)$
- Αρα: $x^T \Sigma_2^{-1} \mu_2 - x^T \Sigma_1^{-1} \mu_1 = 0$
- $\mu_2^\top \Sigma_2^{-1} x = \frac{1}{1.28} \begin{bmatrix} 4.8 & 4.8 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = 7.5(a+b)$
- $\mu_1^\top \Sigma_1^{-1} x = \frac{1}{1.28} \begin{bmatrix} 4.8 & 4.8 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = 7.5(a+b)$
- Αρα: $2\mu_2^\top \Sigma_2^{-1} x - 2\mu_1^\top \Sigma_1^{-1} x = 0$

Τα $\mu_2^\top \Sigma^{-1} x$, $x^T \Sigma^{-1} \mu_2$ και $\mu_1^\top \Sigma^{-1} x$, $x^T \Sigma^{-1} \mu_1$ είναι σαφώς ίδια μεταξύ τους, καθώς είναι βαθμωτά.

Με βάση τα παραπάνω η ανισότητα (2) για το σύνορο απόφασης διαμορφώνεται ως εξής:

- Αποφασίζουμε ω_2 όταν: $\ln\left(\frac{P(\omega_1)}{P(\omega_2)}\right) + \frac{1}{2}\left(1.25ab + 22.5\right) > 0$
- Αποφασίζουμε ω_1 όταν: $\ln\left(\frac{P(\omega_1)}{P(\omega_2)}\right) + \frac{1}{2}\left(1.25ab + 22.5\right) < 0$

b. Σχεδιάζουμε τις ομοϋψείς καμπύλες στη matlab με χρήση της ρουτίνας contour.

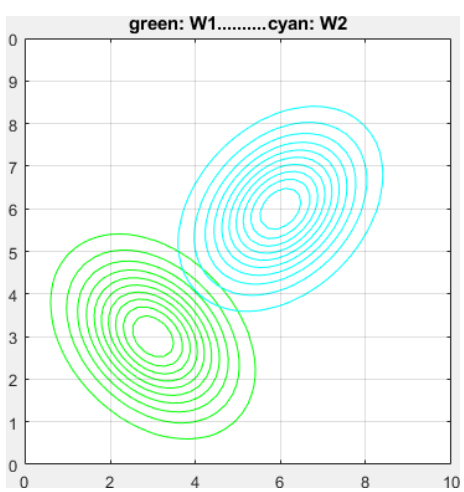

Figure 1: ισοϋψείς καμπύλες των δεσμευμένων πιθανοτήτων $P(x|\omega_i) \in R2$ για κάθε κλάση i.

c. Παρατηρούμε αρχικά ότι το σύνορο απόφασης είναι καμπύλη καθώς ο πίνακας συνδιασποράς των ω1, ω2 είναι διαφορετικός και υπάρχει εξάρτηση μεταξύ των χαρακτηριστικών λόγω των μη μηδενικών στοιχείων τους. Παρατηρούμε επίσης ότι όσο αυξάνεται η εκ των προτέρων πιθανότητα της ω1, τόσο απομακρύνεται από το μέσο της το σύνορο απόφασης. Αυτό συμβαίνει διότι αυξάνεται το ύψος της πρώτης pdf και καλύπτει μεγαλύτερο μέρος της δεύτερης.

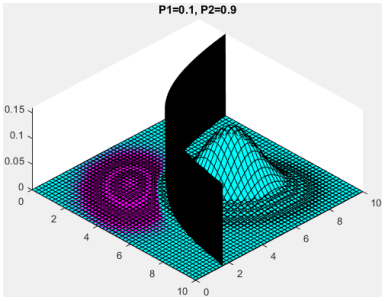

(a) $P_1 = 0.1$.

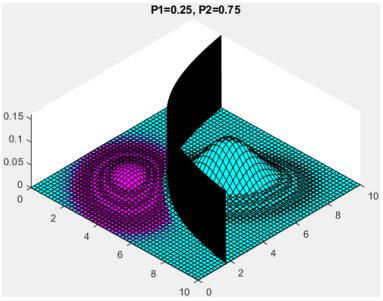

(b) $P_1 = 0.25$.

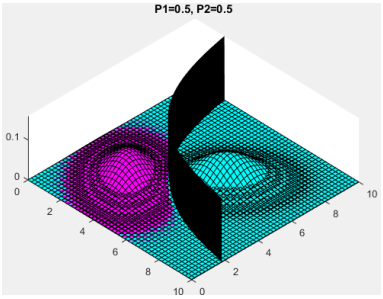

(c) $P_1 = 0.5$.

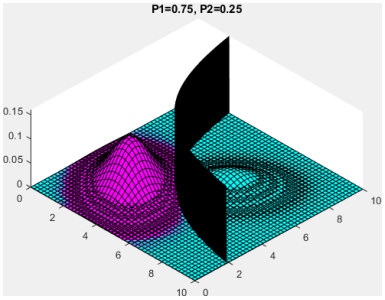

(d) $P_1 = 0.75$.

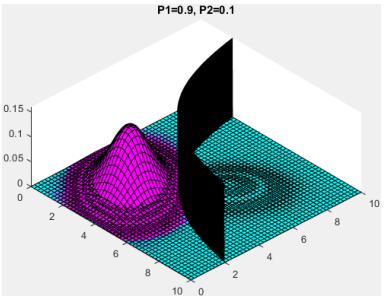

(e) $P_1 = 0.9$.

Figure 2: Κατανομές και σύνορα απόφασης για διάφορες τιμές του P_1

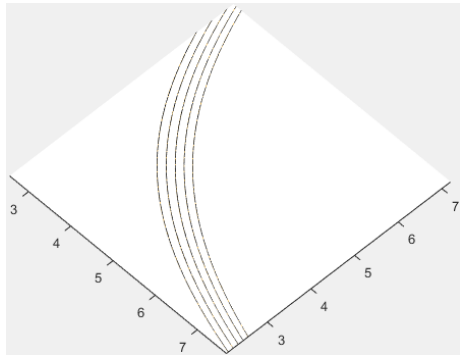

Figure 3: Κάτοψη των συνόρων απόφασης για διάφορες τιμές του P_1.

d. Επαναλαμβάνεται η ίδια διαδικασία με παραπάνω για $\Sigma 1 = \Sigma 2 = \Sigma = \begin{bmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{bmatrix}$.
Έτσι, για να βρούμε το βέλτιστο σύνορο απόφασης (διαχωρισμού) πρέπει να ελαχιστοποιήσουμε την πιθανότητα λάθους:
$P_{err} = P(\omega_1)P(\omega_2|\omega_1) + P(\omega_2)P(\omega_1|\omega_2) =$

$= P(\omega_1)(1 - P(x \in R_1|\omega_2)) + P(\omega_2)P(x \in R_1|\omega_2) =$

$= P(\omega_1) - P(\omega_1)P(x \in R_1|\omega_1) + P(\omega_2)P(x \in R_1|\omega_2) =$

$= P(\omega_1) - P(\omega_1)\int_{R_1} f_{x|\omega_1}(y)dy + P(\omega_2)\int_{R_1} f_{x|\omega_2}(y)dy =$

$= P(\omega_1) + \int_{R1}(P(\omega_2)f_{x|\omega_2}(y) \ -P(\omega_1)f_{x|\omega_1}(y))dy =$

$= P(\omega_1) + \int_{R1} f_x(y)(P(\omega_2|x = y) - P(\omega_1|x = y))dy$

Τα $P(\omega_1), P(\omega_2), f_x(y), P(\omega_1|x = y), P(\omega_2|x = y)$ δεν αλλάζουν. μπορούμε μόνο να πειράξουμε την περιοχή ολοκλήρωσης R_1 οπότε, ο κανόνας απόφασης είναι:
$P(\omega_2|x = y) \gtrless P(\omega_1|x = y)$ και μέσω του θεωρήματος Bayes γίνεται:

$\frac{P(\omega_2)f_{(x|\omega_2)}(y)}{f_x(y)} \gtrless \frac{P(\omega_1)f_{(x|\omega_1)}(y)}{f_x(y)} \Rightarrow P(\omega_2)f_{(x|\omega_2)}(y) \gtrless P(\omega_1)f_{(x|\omega_1)}(y) \Rightarrow$

$\Rightarrow P(\omega_2)\frac{1}{((2\pi)^2|\Sigma|)^{1/2}} \exp(-\frac{1}{2}(x - \mu_2)^T\Sigma^{-1}(x - \mu_2)) \gtrless$
$P(\omega_1)\frac{1}{((2\pi)^2|\Sigma|)^{1/2}} \exp(-\frac{1}{2}(x - \mu_1)^T\Sigma^{-1}(x - \mu_1)) \Rightarrow$

$\Rightarrow P(\omega_2)(\frac{1}{(2\pi)^2|\Sigma|)^{1/2}}) \ e^{-(1/2)(x-\mu_2)^T\Sigma^{-1}(x-\mu_2)} \gtrless$

$P(\omega_1)(\frac{1}{(2\pi)^2|\Sigma|)^{1/2}})\ e^{-(1/2)(x-\mu_1)^T\Sigma^{-1}(x-\mu_1)} \Rightarrow$

$\ln(\frac{P(\omega_2)}{P(\omega_1)}) + \frac{1}{2}(-x^T\Sigma^{-1}x + x^T\Sigma^{-1}\mu_2 - \mu_2^T\Sigma^{-1}\mu_2 + \mu_2^T\Sigma^{-1}x + x^T\Sigma^{-1}x - x^T\Sigma^{-1}\mu_1 - \mu_1\Sigma^{-1}x + \mu_1^T\Sigma^{-1}\mu_1) \gtrless 0 \Rightarrow$

$\ln(\frac{P(\omega_2)}{P(\omega_1)}) + \frac{1}{2}(x^T\Sigma^{-1}\mu_2 - x^T\Sigma^{-1}\mu_1 + \mu_2^T\Sigma^{-1}x - \mu_1\Sigma^{-1}x - \mu_2^T\Sigma^{-1}\mu_2 + \mu_1^T\Sigma^{-1}\mu_1) \gtrless 0$

Παρακάτω παρατίθενται τα αποτελέσματα των στοιχείων:

- $\Sigma^{-1} = \frac{1}{(1.2^2-(-0.4)^2)}\begin{bmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{bmatrix} = \frac{1}{1.28}\begin{bmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{bmatrix}$
- $\mu_2^T\Sigma^{-1}\mu_2 = \frac{1}{1.28}\begin{bmatrix} 6 & 6 \end{bmatrix}\begin{bmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{bmatrix}\begin{bmatrix} 6 \\ 6 \end{bmatrix} = 45$
- $\mu_1^T\Sigma^{-1}\mu_1 = \frac{1}{1.28}\begin{bmatrix} 3 & 3 \end{bmatrix}\begin{bmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{bmatrix}\begin{bmatrix} 3 \\ 3 \end{bmatrix} = 11.25$
- Αρα: $-\mu_2^T\Sigma^{-1}\mu_2 + \mu_1^T\Sigma^{-1}\mu_1 = -33.75$
- $x^T\Sigma^{-1}\mu_2 = \frac{1}{1.28}\begin{bmatrix} a & b \end{bmatrix}\begin{bmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{bmatrix}\begin{bmatrix} 6 \\ 6 \end{bmatrix} = 3.75(a+b)$
- $x^T\Sigma^{-1}\mu_1 = \frac{1}{1.28}\begin{bmatrix} a & b \end{bmatrix}\begin{bmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{bmatrix}\begin{bmatrix} 3 \\ 3 \end{bmatrix} = 1.875(a+b)$
- Αρα: $x^T\Sigma^{-1}\mu_2 - x^T\Sigma^{-1}\mu_1 = 1.875(a+b)$
- $\mu_2^\top\Sigma^{-1}x = \frac{1}{1.28}\begin{bmatrix} 4.8 & 4.8 \end{bmatrix}\begin{bmatrix} a \\ b \end{bmatrix} = 3.75(a+b)$
- $\mu_1^\top\Sigma^{-1}x = \frac{1}{1.28}\begin{bmatrix} 4.8 & 4.8 \end{bmatrix}\begin{bmatrix} a \\ b \end{bmatrix} = 1.785(a+b)$
- Αρα: $\mu_2^\top\Sigma^{-1}x - \mu_1^\top\Sigma_1^{-1}x = 1.785(a+b)$

Τα $\mu_2^\top\Sigma^{-1}x$, $x^T\Sigma^{-1}\mu_2$ και $\mu_1^\top\Sigma^{-1}x$, $x^T\Sigma^{-1}\mu_1$ είναι σαφώς ίδια μεταξύ τους, καθώς είναι βαθμωτά.

Από τα παραπάνω το σύνορο απόφασης, όταν οι πίνακες συνδιασποράς είναι ίδιοι, διαμορφώνεται ως εξής:

- Αποφασίζουμε ω_2 όταν: $\ln\left(\frac{P(\omega_1)}{P(\omega_2)}\right) + \frac{1}{2}\left(3.75(a+b) - 33.75\right) > 0$
- Αποφασίζουμε ω_1 όταν: $\ln\left(\frac{P(\omega_1)}{P(\omega_2)}\right) + \frac{1}{2}\left(3.75(a+b) - 33.75\right) < 0$

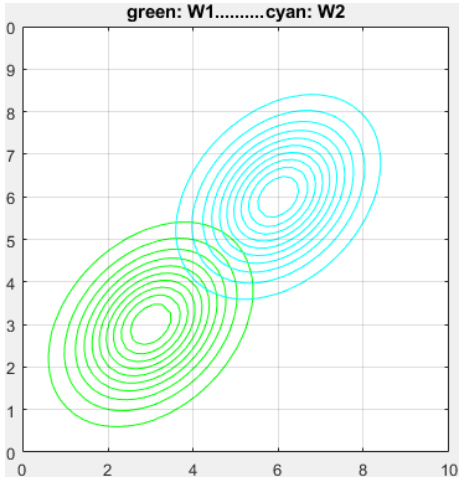

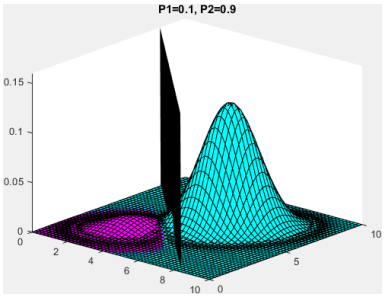

(a) $P_1 = 0.1$.

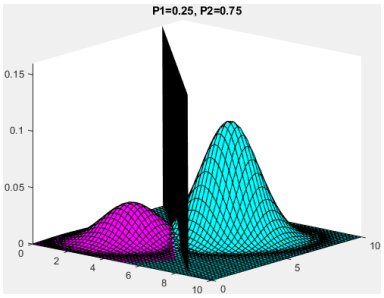

(b) $P_1 = 0.25$.

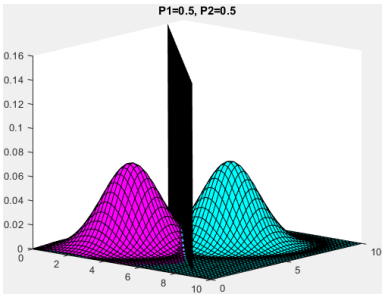

(c) $P_1 = 0.5$.

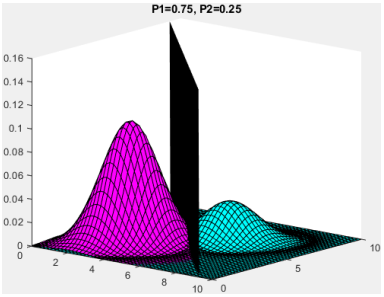

(d) $P_1 = 0.75$.

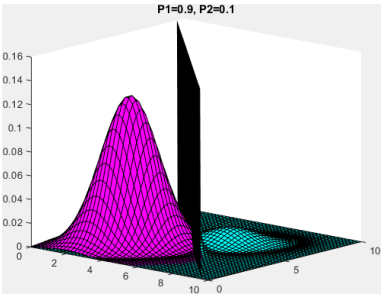

(e) $P_1 = 0.9$.

Figure 4: Κατανομές και σύνορα απόφασης για διάφορες τιμές του P_1

Παρατηρούμε ότι το νέο επίπεδο δεν είναι κυρτό, όπως στην περίπτωση που $\Sigma_1 \neq \Sigma_2$, αλλά είναι γραμμικό. Αυτό είναι λογικό καθώς οι δύο κατανομές έχουν όμοια μορφή και ,όπως είναι γνώστό από την θεωρία, το επίπεδο σε αυτή την περίπτωση θα είναι γραμμικό ανεξάρτητα των εκ των προτέρων πιθανοτήτων $P(\omega_2)$ και $P(\omega_1)$.

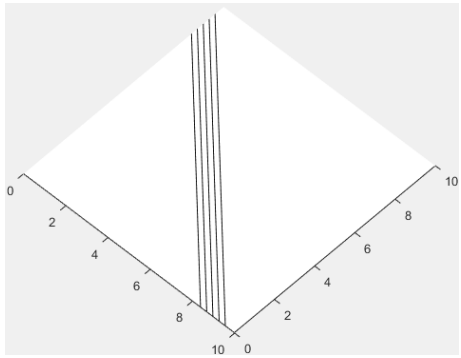

Figure 5: Κάτοψη των συνόρων απόφασης για διάφορες τιμές του P_1.

Θέμα 2: Εξαγωγή χαρακτηριστικών και Bayes Classification.

α. Αρχικά φορτώσαμε και χωρίσαμε τα δεδομένα των ψηφίων 1 και 2 σε train data, τα οποία θα χρησιμοποιηθούν για την εύρεση του κανόνα απόφασης και στα test data με τα οποία θα εκτιμήσουμε την απόδοση/ακρίβεια του αλγορίθμου ταξινόμησης. Αυτό έγινε με χρήση της load και της έτοιμης ρουτίνας που μας δόθηκε (read_data).

Έπειτα συμπληρώσαμε κώδικα στη ρουτίνα υπολογισμού του λόγου όψεος (aspect ratio), ο οποίος ορίζεται ως ο λόγος width/height του ελάχιστου ορθογωνίου που περικλείει ένα ψηφίο και την χρησιμοποιήσουμε για να υπολογίσουμε τον λόγο αυτό για κάθε εικόνα των ψηφίων 1 και 2. Ο λόγος όψεος είναι το μονοδιάστατο χαρακτηριστικό με βάση το οποίο θα κάνουμε την ταξινόμηση.

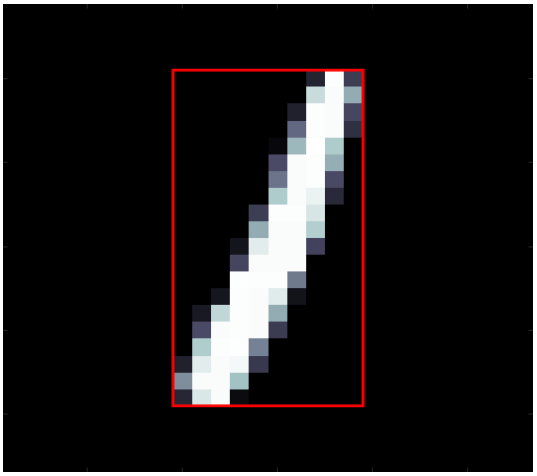

(a) Παράδειγμα εικόνας ψηφίου 1.

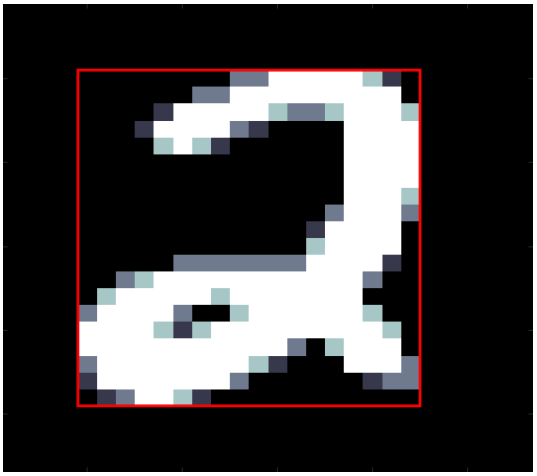

(b) Παράδειγμα εικόνας ψηφίου 2.

Figure 6: Παραδείγματα εικόνων ψηφίου με σχεδιασμένο τον λόγο όψεος.

Υπολογίστηκε επίσης το ελάχιστο και το μέγιστο aspect ratio για το σύνολο των δύο ειδών εικόνων:

Minimum aspect ratio: 0.1
Maximum aspect ratio: 2.2222

Figure 7: Ελάχιστο και μέγιστο aspect ratio.

β. Υπολογίστηκαν οι a-priori πιθανότητες των δύο κλάσεων ως ο λόγος του αριθμού των εικόνων της κάθε κλάσης προς τον συνολικό αριθμό εικόνων $\frac{N_i}{N_1+N_2}$ για $i = 1, 2$. Χρησιμοποιούμε τον συμβολισμό $C1$ και $C2$ για την κλάση των εικόνων που περιέχουν τα ψηφία 1 και 2 αντίστοιχα

Prior Probability of C1: 0.53087
Prior Probability of C2: 0.46913

Figure 8: Priors των κλάσεων C1, C2.

γ. Υποθέτωντας ότι η κατανομή του aspect ratio σε κάθε κλάση ακολουθεί κανονική κατανομή, μπορούμε να εκτιμήσουμε την μέση τιμή και την διασπορά της κάθε κατανομής με χρήση των παρακάτω τύπων:

$\overline{\mu} = \frac{1}{N}\sum_{i=1}^{N} x_i$ και $\overline{\sigma} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(x_i - \overline{\mu})^2}$, όπου x_i ο λόγος όψεος των train data.

m1: 0.4677
m2: 0.96055
...
s1: 0.19977
s2: 0.18832

Figure 9: μέσες τιμές και διασπορές των κατανομών των κλάσεων C1, C2.

Παρατηρούμε ότι οι διασπορές των κατανομών δεν είναι ίσες γεγονός που θα οδηγήσει στην εύρεση **2** σημείων απόφασης.

Στη συνέχεια βρίσκουμε τα likelihoods των στοιχείων και τις a-posteriori πιθανότητες των κλάσεων $C1, C2$ και υλοποιούμε τον Bayes ταξινομητή.

x1: 0.72633
x2: 9.0607

Figure 10: σημεία απόφασης.

Στην πραγματικότητα η εμφάνιση ενός ψηφίου 1 ή 2 με aspect ratio μεγαλύτερο του $x_2 = 9.0607$ είναι απίθανη άρα θα μπορούσαμε να αγνοήσουμε το 2ο σημείο απόφασης.

Πλέον μπορούμε να ταξινομήσουμε τα test data και να ελέγξουμε αν η απόφαση ήταν σωστή κοιτάζοντας σε ποια κλάση αυτά ήταν αρχικά τοποθετημένα. Το ποσοστό σφάλματος και η ακρίβεια της ταξινόμησης βρέθηκαν να είναι:

```
Error percentage: 10.9368%
Accuracy: 89.0632%
```

Figure 11: Σφάλμα και ακρίβεια.

Θέμα 3: Minimum Risk

Αρχικά, ορίζουμε το ρίσκο κάθε απόφασης:

- $l1 = \lambda_{11}P(\omega_1)p(x|\omega_1) + \lambda_{21}P(\omega_2)p(x|\omega_2) = \lambda_{21}P(\omega_2)p(x|\omega_2)$, επειδή $\lambda_{11} = 0$
- $l2 = \lambda_{12}P(\omega_1)p(x|\omega_1) + \lambda_{22}P(\omega_2)p(x|\omega_2) = \lambda_{12}P(\omega_1)p(x|\omega_1)$, επειδή $\lambda_{22} = 0$

Αρα για να ελαχιστοποιήσουμε το ρίσκο, παίρνουμε την περίπτωση, όπου $l_1 = l_2$:

$l_1 = l_2 \Leftrightarrow \lambda_{21}P(\omega_2)p(x|\omega_2) = \lambda_{12}P(\omega_1)p(x|\omega_1) \Leftrightarrow \ln\left(\frac{p(x|\omega_1)}{p(x|\omega_2)}\right) = \ln\left(\frac{\lambda_{21}P(\omega_2)}{\lambda_{12}P(\omega_1)}\right)$ (1), όπου:
$\ln\left(\frac{p(x|\omega_1)}{p(x|\omega_2)}\right) = \ln(p(x|\omega_1)) - \ln(p(x|\omega_2)) = \ln\left(\frac{x}{\sigma_1^2}e^{-\frac{x^2}{2\sigma_1^2}}\right) - \ln\left(\frac{x}{\sigma_2^2}e^{-\frac{x^2}{2\sigma_2^2}}\right) =$
$\ln\left(\frac{x}{1}e^{-\frac{x^2}{2}}\right) - \ln\left(\frac{x}{2^2}e^{-\frac{x^2}{2\cdot 2^2}}\right) = \ln(x) + \ln(e^{-\frac{x^2}{2}}) - \left(\ln(x) + \ln\left(e^{-\frac{x^2}{8}}\right) - \ln(4)\right) =$
$-\frac{x^2}{2} + \frac{x^2}{8} + 2\ln(2) = -\frac{3x^2}{8} + 2\ln(2)$

Επίσης: $\ln\left(\frac{\lambda_{21}P(\omega_2)}{\lambda_{12}P(\omega_1)}\right) = \ln\left(\frac{\lambda_{21}}{\lambda_{12}}\right) = \ln\left(\frac{1}{0.5}\right) = \ln(2)$.

Οπότε, η αρχική ισότητα (1) γίνεται: $-\frac{3x^2}{8} + 2\ln(2) = \ln(2) \Rightarrow x_0 = \sqrt{\frac{8}{3}\ln(2)} \approx 1.359$, όπου το x_0 είναι το ζητούμενο σύνορο απόφασης, το οποίο ελαχιστοποιεί το μέσο ρίσκο.

Θέμα 4: Singular Value Decomposition(SVD)

1. Αρχικά, υπολογίζεται ο πίνακας $X^\top X$ ως εξής:

$$X^\top X = \begin{bmatrix} 1 & -1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 1 \\ -1 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 2 & -1 & 1 \\ -1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

Οι ζητούμενες ιδιοτιμές είναι οι λύσεις της εξίσωσης

$$(X^\top X - \lambda I) = 0 \Rightarrow \det \begin{bmatrix} 2-\lambda & -1 & 1 \\ -1 & 1-\lambda & 0 \\ 1 & 0 & 1-\lambda \end{bmatrix} = 0 \Rightarrow$$

$$(2-\lambda) \begin{vmatrix} 1-\lambda & 0 \\ 0 & 1-\lambda \end{vmatrix} - (-1) \begin{vmatrix} -1 & 0 \\ 1 & 1-\lambda \end{vmatrix} + 1 \begin{vmatrix} -1 & 1-\lambda \\ 1 & 0 \end{vmatrix} = 0 \Rightarrow \lambda^3 - 4\lambda^2 + 3\lambda = 0$$

Οι λύσεις της παραπάνω εξίσωσης υπολογίζονται : $\lambda_1 = 0$, $\lambda_2 = 1$ και $\lambda_3 = 3$, οι οποίες είναι και οι ιδιοτιμές του $X^\top X$.

Για κάθε ιδιοτιμή υπολογίζεται το αντίστοιχο ιδιοδιάνυσμα.

- Για $\lambda_1 = 0$: $[X^T X - \lambda_1 I]\mathbf{v}_1 = 0 \Rightarrow X^T X \mathbf{v}_1 = \begin{bmatrix} 2 & -1 & 1 \\ -1 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$

Έτσι, προκύπτει το σύστημα των ακόλουθων εξισώσεων: $2x - y + z = 0$, $-x + y = 0$, $x + z = 0$ από το οποίο συμπεραίνεται ότι το ιδιοδιάνυσμα για λ = 0 είναι: $v_1 = \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix}$

- Για $\lambda_2 = 1$: $[X^T X - \lambda_2 I]\mathbf{v}_2 = 0 \Rightarrow X^T X \mathbf{v}_2 = \begin{bmatrix} 1 & -1 & 1 \\ -1 & 0 & 0 \\ 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$

Έτσι, προκύπτει το σύστημα των ακόλουθων εξισώσεων: $x - y + z = 0$, $-x = 0$, $x = 0$ από το οποίο συμπεραίνεται ότι το ιδιοδιάνυσμα για λ = 1 είναι: $v_2 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}$

- Για $\lambda_3 = 3$: $[X^T X - \lambda_3 I]\mathbf{v}_3 = 0 \Rightarrow X^T X \mathbf{v}_3 = \begin{bmatrix} -1 & -1 & 1 \\ -1 & -2 & 0 \\ 1 & 0 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$

Έτσι, προκύπτει το σύστημα των ακόλουθων εξισώσεων: $-x - y + z = 0$, $-x - 2y = 0$, $x + 2z = 0$ από το οποίο συμπεραίνεται ότι το ιδιοδιάνυσμα για λ = 3

είναι: $v_3 = \begin{bmatrix} 2 \\ -1 \\ 1 \end{bmatrix}$

Κανονικοποιώντας τα ιδιοδιανύσματα παίρνουμε: $V_1 = \begin{bmatrix} \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{3}} \end{bmatrix}$, $V_2 = \begin{bmatrix} 0 \\ \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$,

$V_3 = \begin{bmatrix} \frac{2}{\sqrt{6}} \\ -\frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{6}} \end{bmatrix}$

2. Singular values: $S_1 = 1$ και $S_2 = \sqrt{3}$. Υπολογίζεται, επίσης για λ = 3, το μη-μηδενικό ιδιοδιάνυσμα:

$$U_3 = S_2 X V_3 \ = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 & 0 & 1 \\ -1 & 1 & 0 \end{bmatrix} \begin{bmatrix} \frac{2}{\sqrt{6}} \\ -\frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{6}} \end{bmatrix} \ = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$$

3. Υπολογίζεται, αρχικά, ο πίνακας $XX^\top = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$.

   Ακολουθώντας την ίδια διαδικασία με παραπάνω λύνεται η ακόλουθη εξίσωση:
   $(XX^\top - \lambda I) = 0 \Rightarrow \det \begin{bmatrix} 2-\lambda & -1 \\ -1 & 2-\lambda \end{bmatrix} = 0$

   Λύνοντας την ορίζουσα προκύπτουν οι λύσεις - ιδιοτιμές: $\lambda_1 = 1$ και $\lambda_2 = 3$. Για τον υπολογισμό των αντίστοιχων ιδιοδιανυσμάτων, όπως και παραπάνω:

   - Για $\lambda_1 = 1$: $[XX^T - \lambda_1 I]\mathbf{v'}_1 = 0 \Rightarrow XX^T\mathbf{v'}_1 = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$

   Έτσι, προκύπτει το σύστημα των ακόλουθων εξισώσεων: $x - y = 0$, $-x + y = 0$ από το οποίο συμπεραίνεται ότι το ιδιοδιάνυσμα για λ = 1 είναι: $v'_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

   - Για $\lambda_2 = 3$: $[XX^T - \lambda_2 I]\mathbf{v'}_2 = 0 \Rightarrow XX^T\mathbf{v'}_2 = \begin{bmatrix} -1 & -1 \\ -1 & -1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$

Έτσι, προκύπτει το σύστημα των ακόλουθων εξισώσεων: $-x - y = 0$, $-x - y = 0$ από το οποίο συμπεραίνεται ότι το ιδιοδιάνυσμα για λ = 1 είναι: $v_2' = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$.

Κανονικοποιώντας τα ιδιοδιανύσματα παίρνουμε: $V_1' = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$, $V_2' = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$.

Τα μη-μηδενικά ιδιοδιανύσματα του $X * X^T$, επομένως, υπολογίζονται από τον τύπο: $U_i' = \frac{1}{\sqrt{\lambda_i}} X V_i'$. 'ρα, είναι:$U_{\lambda=1}' = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$ και $U_{\lambda=3}' = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$.

4. Για την καλύτερη rank-1 προσέγγιση του $\hat{X}$ χρησιμοποιείται η μεγαλύτερη ιδιοτιμή, δηλαδή $\lambda = 3$.

Συνεπώς:

$$\hat{X} = U_{\lambda=3}' \cdot S_{\lambda=3}' \cdot V_3^T = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} \cdot \sqrt{3} \cdot \begin{bmatrix} \frac{2}{\sqrt{6}} & -\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{6}} \end{bmatrix} = \begin{bmatrix} 1 & -0.5 & 0.5 \\ -1 & 0.5 & -0.5 \end{bmatrix}$$

Θέμα 5: Principal Component Analysis (PCA).

Μέρος 1

Στο 1ο μέρος θα εφαρμόσουμε Principal Component Analysis (PCA) σε ένα σύνολο 2-D δεδομένων, ώστε να μειώσουμε την διάστασή τους σε 1-D.

a. Αρχικά φορτώνουμε τα δεδομένα με χρήση της load και τα απεικονίζουμε πριν την κανονικοποίηση στις 2 διαστάσεις:

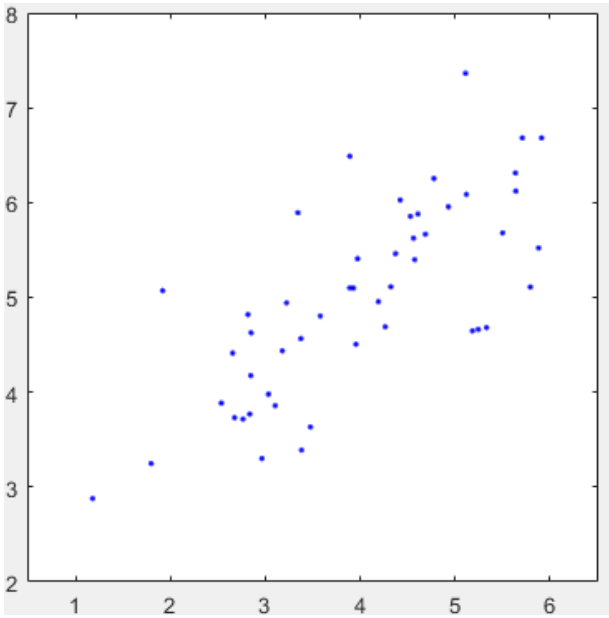

Figure 12: Δεδομένα σε 2-D χώρο.

b. Κανονικοποιούμε τα παραπάνω δεδομένα, ώστε να έχουν μέση τιμή 0 και διασπορά 1 και τα συγκρίνουμε με τα αρχικά. Παρατηρούμε ότι τα κανονικοποιημένα δεδομένα συγκεντρώνονται γύρω από το μηδέν και απλώνονται λιγότερο στον χώρο από ότι τα μη κανονικοποιημένα Αυτό συμβαίνει λόγω της νέας μέσης τιμής στο 0 και της διασποράς (η οποία είναι μικρότερη από την αρχική).

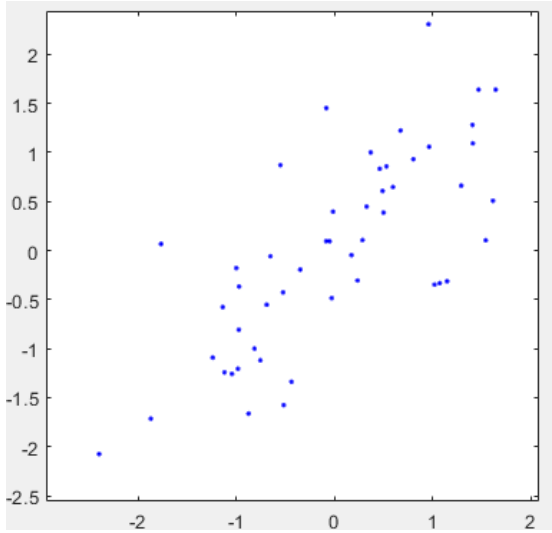

Figure 13: Δεδομένα σε 2-D χώρο.

c. Με κώδικα που συμπήρώνουμε στη ρουτίνα myPCA εφαρμόζουμε eigenvalue decomposition στον πίνακα συνδιασποράς των δεδομένων και ταξινομώντας τα στοιχεία των πινάκων που προκύπτουν, λαμβάνουμε τις κύριες συνιστώσες και τις σχεδιάζουμε στο ίδιο plot με τα κανονικοποιημένα δεδομένα.

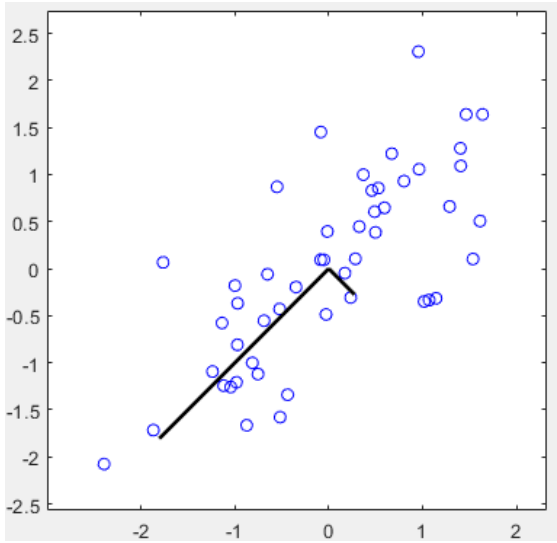

Figure 14: Δεδομένα και κύριες συνιστώσες του PCA σε 2-D χώρο.

d. Στη συνέχεια υπολογίζουμε την συνεισφορά της κάθε κύρια συνιστώσας στην συνολική διακύμανση με χρήση του τύπου: $Var(PC_i) = \frac{\lambda_i}{\sum_{j=1}^{2} \lambda_i}$ για $i = 1, 2$. Η μεγαλύτερη από τις δύο θα χρησιμοποιηθεί για να προβάλλουμε τα δεδομένα στη μία διάσταση, ώστε να κρατήσουμε όσο το δυνατόν περισσότερη πληροφορία. Προκύπτει ότι η πρώτη κύρια συνιστώσα συνεισφέρει κατά 0.8678, ενώ η δεύτερη κατά 0.1322.

```
PCvariance = 0.867765 0.132235

(you should expect to see 0.8678 and 0.1322)
```

Figure 15: συνεισφορά της κάθε κύριας συνιστώσας.

Προβάλλουμε τα δεδομένα στη διεύθυνση της συνιστώσας με την μεγαλύτερη συνεισφορά με την projectData.

e. Τέλος ανακτάμε τα δεδομένα στον αρχικό 2-D χώρο (με την recoverData) και τα σχεδιάζουμε στο ίδιο plot με τα κανονικοποιήμενα. Παρατηρούμε ότι προβάλλοντας σε αυτή τη διεύθυνση τα δεδομένα που προέκυψαν απλώνονται στο μέγιστο μήκος.

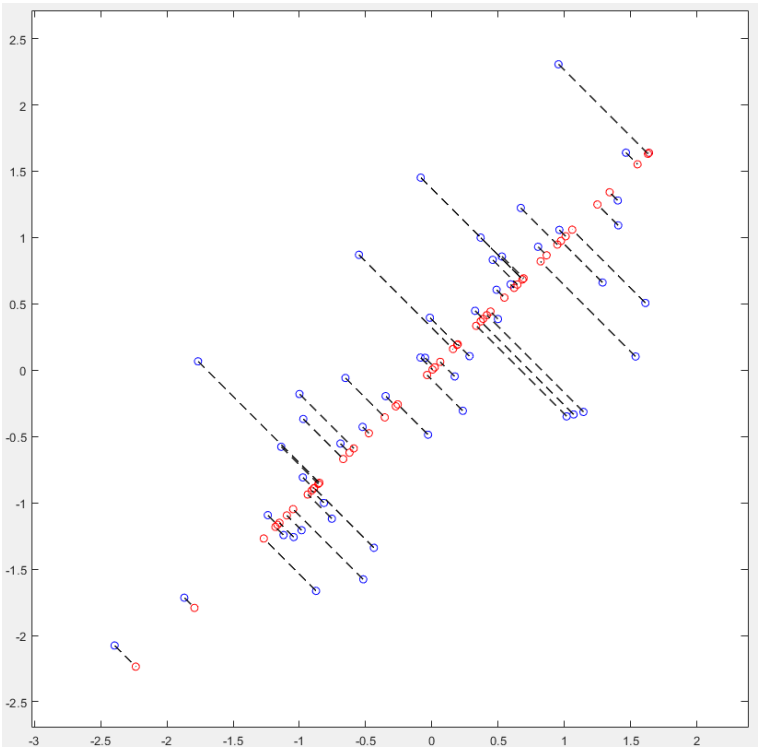

Figure 16: Μπλε: κανονικοποιημένα 2-D δεδομένα —Κόκκινο: Αναπαραγωγή δεδομένων.

Μέρος 2

Επαναλαμβάνουμε την ίδια διασικασία χρησιμοποιώντας πολυδιάστατα δεδομένα ώστε να φανεί καλύτερα το αποτέλεσμα τις μείωσης διαστάσεων με τον αλγόριθμο PCA.

f. Φορτώνουμε αρχικά τα δεδομένα 5000 εικόνων προσώπων και σχεδιάζουμε τα πρώτα 100 από αυτά με την ρουτίνα displayData:

Figure 17: Εικόνες προσώπων του dataset.

g. Με χρήση των ρουτινών normalizeData και myPCA που δημηουργήθηκαν στο πρώτο μέρος, κανονικοποιούμε τις εικόνες προσώπων και βρίσκουμε τις κύριες συνιστώσες με eigenvalue decomposition.

Figure 18: κύριες συνιστώσες του PCA.

Σε αυτό το σημείο σχεδιάστηκαν ανάποδα οι κύριες συνιστώσες. Παρ΄ ολ΄ αυτά, φαίνεται ότι όσο προχωράμε σε συνιστώσες από την πρώτη, τόσο λιγότερο αυτές μοιάζουν με πρόσωπο, γεγονός που επιβεβαιώνει ότι ο αλγόριθμος δούλεψε σωστά.

h. Χρησιμοποιούμε την ρουτίνα projectData με όρισμα το K=100, ώστε να προβάλλουμε στις 100 πρώτες κύριες συνιστώσες, δηλαδή στα πρώτα 100 ιδιοδιανύσματα που λάβαμε από την myPCA.

i. Τέλος αναπαράγουμε τα δεδομένα μέσω της recoverData και σχεδιάζουμε τα πρώτα 100 δείγματα του αποτελέσματος σε νέο plot, με χρήση της displayData.

Figure 19: Σύγκριση των αρχικών και των ανακτημένων εικόνων.

Παρατηρούμε ότι οι εικόνες που ανακτήσαμε μοιάζουν σε μεγάλο βαθμό με τις αρχικές, επομένως πετύχαμε ικανοποιητική μείωση διαστάσεων των αρχικών δεδομένων.

Επαναλαμβάνουμε τα δύο τελευταία βήματα για K=10, 50, 100.

(a) Προβολή σε πρώτες 10 κύριες συνιστώσες.

(b) Προβολή σε πρώτες 50 κύριες συνιστώσες.

(c) Προβολή σε πρώτες 200 κύριες συνιστώσες.

Παρατηρούμε ότι όσο αυξάνουμε το K τόσο καλύτερη γίνεται η ανάκτηση των εικόνων με την βελτίωση αυτή να γίνεται όλο και λιγότερο αισθητή. Αυτό το συμπέρασμα είναι λογικό, καθώς οι πρώτες κύριες συνιστώσες είναι αυτές που συνεισφέρουν περισσότερο στη συνολική διακύμανση.

Θέμα 6: Σχεδιάστε έναν ταξινομητή LDA(Linear Discriminant Analysis)

Για τον υπολογισμό του διανύσματος προβολής w χρησιμοποιείται η μέθοδος Fisher's Linear Discriminant Analysis, όπου το διάνυσμα υπολογίζεται από τον τύπο:

$$w = \left(Sw^{-1}\right)(m_1 - m_2) \tag{1}$$

Βρίσκουμε:

- μ1 - μ2:

$$m1 - m2 = \begin{bmatrix} -5 \\ 5 \end{bmatrix} - \begin{bmatrix} 10 \\ 15 \end{bmatrix} \qquad = \begin{bmatrix} -5-10 \\ 5-15 \end{bmatrix} = \begin{bmatrix} -15 \\ -10 \end{bmatrix}$$

- Sw = S1+S2:

$$S1 - S2 = \begin{bmatrix} 11 & 9 \\ 9 & 11 \end{bmatrix} - \begin{bmatrix} 12 & 0 \\ 10 & 2 \end{bmatrix} \qquad = \begin{bmatrix} 13 & 9 \\ 9 & 13 \end{bmatrix}$$

- Sw^{-1} : $Sw^{-1} = \frac{1}{(13^2-9^2)*0.5} \begin{bmatrix} 13 & -9 \\ -9 & 13 \end{bmatrix} = \frac{1}{44} \begin{bmatrix} 13 & -9 \\ -9 & 13 \end{bmatrix}$

Επομένως, το διάνυσμα προβολής είναι:
$w = Sw^{-1}(m1 - m2) = \frac{1}{44} \begin{bmatrix} 13 & -9 \\ -9 & 13 \end{bmatrix} \begin{bmatrix} -15 \\ -10 \end{bmatrix} = \frac{1}{44} \begin{bmatrix} -105 \\ 5 \end{bmatrix}$

Θέμα 7: Linear Discriminant Analysis (LDA) vs PCA.

Μέρος 1

Στο 1ο μέρος θα εφαρμόσουμε Fisher's Linear DIscriminant Analysis (LDA) σε ένα σύνολο 2-D δεδομένων, ώστε να μειώσουμε την διάστασή τους σε 1-D. Στη συνέχεια θα εφαρμόσουμε PCA στο ίδιο αρχικό σύνολο και θα συγκρίνουμε τα αποτελέσματα των δύο μεθόδων.

a. Αρχικά φορτώνουμε τα 2-D δεδομένα με χρήση της load. Τα δεδομένα είναι 14 στον αριθμό και ανήκουν είτε στην κλάση 1, είτε στην 2 σύμφωνα με τα labels τους.

b. Χωρίζουμε τα δεδομένα με βάση το labels τους, τα κανονικοποιούμε με χρήση της featureNormalize, ώστε να έχουν μέση τιμή 0 και διασπορά 1, και, έπειτα τα σχεδιάζουμε στις δύο διαστάσεις με διαφορετικό χρώμα για κάθε κλάση.

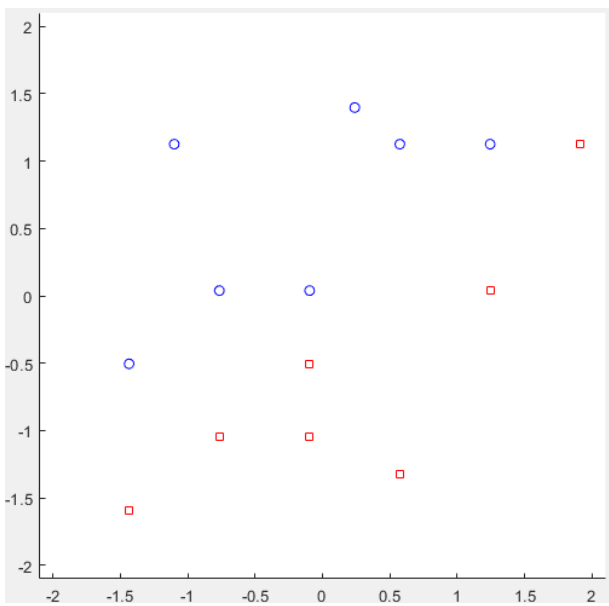

Figure 21: Απεικόνιση δεδομένων στις 2 διαστάσεις.

c. Συμπληρώθηκε ο κώδικας στο FishersLinearDiscriminant, με σκοπό την εύρεση του βέλτιστου διανύσματος, πάνω στο οποίο, οι προβολές όλων των στοιχείων χωρίζουν κατάλληλα τις δύο κλάσεις. Το επιτυγχάνουμε αυτό βρίσκοντας τον within class scatter matrix (Sw) και εφαρμόζοντας τον τύπο: $v = Sw^{-1}(\mu_1 - \mu_2)$, όπου μ_1 και μ_2 η μέση τιμή της κατανομής της αντίστοιχης κλάσης. Σχεδιάστηκε σε κοινό plot με τα δεδομένα η ευθεία στη διεύθυνση του διανύσματος αυτού.

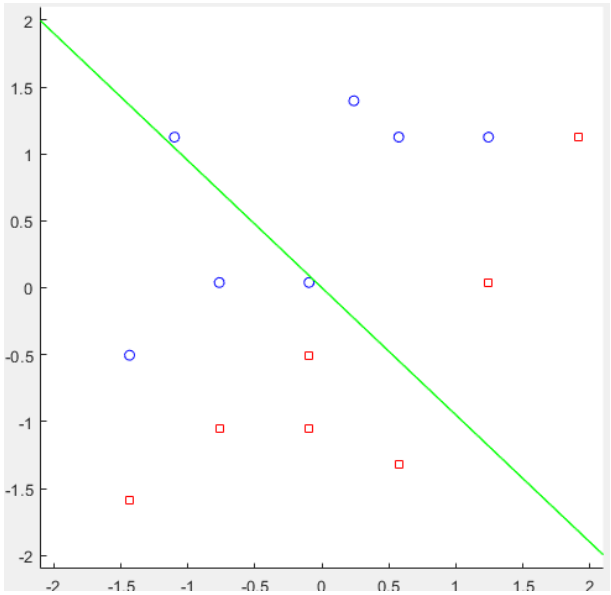

Figure 22: Απεικόνιση της διεύθυνσης του v σε κοινό plot με τα στοιχεία.

Παρατηρείται ότι η ζητούμενη ευθεία σχεδιάζεται στο plot με ανακρίβεια στη γωνία της με τους άξονες. Παρ΄ ολ΄ αυτά ο υπολογισμός του διανύσματος φαίνεται να έγινε επιτυχώς, όπως φαίνεται παρακάτω στην εικόνα με τα ανακατασκευασμένα δειγματα.

d. Στη συνέχεια προβάλλουμε τα αρχικά στοιχεία πάνω στο v μέσω της ρουτίνας projectDataLDA και παίρνουμε τα δείγματα μειωμένης διάστασης.

e. Έπειτα ανακατασκευάζουμε τα δείγματα μέσω της recoverDataLDA, προβάλλοντάς τα πάνω στη διεύθυνση του v και τα σχεδιάζουμε πάνω στο ίδιο plot.

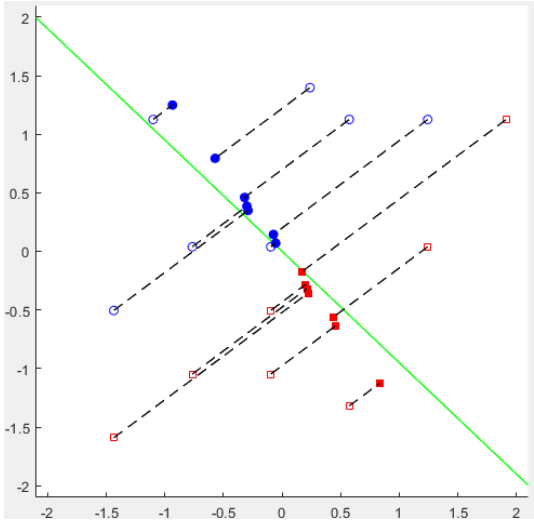

Figure 23: Ανακατασκευασμένα δείγματα με γεμισμένους κύκλους και τετράγωνα.

f. Τέλος εφαρμόζουμε PCA στο ίδιο σύνολο δειγμάτων και συγκίνουμε τα αποτελέσματα των μεθόδων. Βρίσκουμε τις κύριες συνιστώσες και προβάλλουμε τα δείγματα στη διεύθυνση της κύριας συνιστώσας με τη μεγαλύτερη συνεισφορά στη συνολική διακύμανση, όπως ακριβώς αναλύθηκε στο Θέμα 5. Τελικά Λαμβάνουμε τα εξής ανακατασκευασμένα δείγματα:

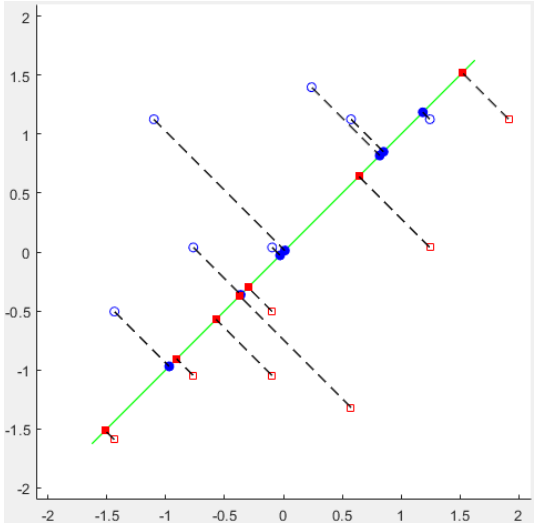

Figure 24: Αποτελέσματα της μεθόδου PCA.

Η βασική διαφορά με την μέθοδο LDA είναι ότι τα ανακατασκευασμένα δείγματα δεν είναι χωρισμένα εκατέρωθεν ενός σημείου της ευθείας, με βάση την κλάση που ανήκουν. Αντ΄ αυτού τα δείγματα προβάλλονται στη διεύθυνση της ευθείας που επιφέρει την μέγιστη διασπορά των στοιχείων πάνω σε αυτήν.
Στην μέθοδο LDA είναι απαραίτητο να γνωρίζουμε την κλάση του κάθε στοιχείου εκ των προτέρων, ενώ στην μέθοδο LDA όχι.

Μέρος 2

Στο 2ο μέρος θα εφαρμόσουμε τον αλγόριθμο LDA στο σύνολο δειγμάτων της βάσης δεδομένων Iris. Η βάση αυτή περιέχει 150 δείγματα που ανήκουν σε 3 κλάσεις, ταξινομημένα με βάση 4 χαρακτηριστικά των λουλουδιών (άρα και 4 διαστάσεις).

a. Φορτώθηκαν τα δείγματα με χρήση της load. Η κλάση στην οποία αυτά ανήκουν αποθηκεύεται στη μεταβλητή "species".

b. Κανονικοποιούμε τα δείγματα, ώστε να κεντραριστούν γύρω από το μηδέν με διασπορά ένα, τα μοιράζουμε σε υποσύνολα ανάλογα με την κλάση τους και τα σχεδιάζουμε σε 2 διαστάσεις χρησιμοποιώντας τα 2 πρώτα χαρακτηριστικά τους.

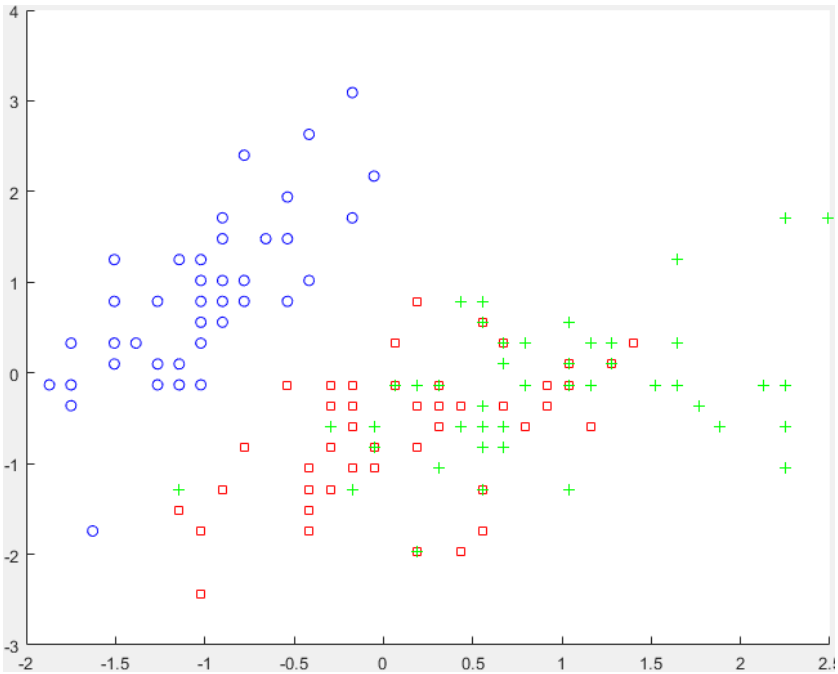

Figure 25: πράσινο: "virginica", μπλε: "setosa", κόκκινο: "versicolor".

c. Συμπληρώθηκε κώδικας στην myLDA η οποία υπολογίζει το κατάλληλο διάνυσμα προβολής. Στην ρουτίνα αυτή υπολογίζουμε το μέσο της κατανομής και την a-priori πιθανότητατης της κάθε κλάσης, τον ολικό μέσο $\mu_0 = \frac{\mu_1+\mu_2+\mu_3}{3}$. Έπειτα βρίσκουμε τον πίνακα σκέδασης $Sw = \sum_{i=1}^{3} P_i \Sigma_i$ (Within-Class Scatter Matrix), καθώς και τον πίνακα σκέδασης $S_b = \sum_{i=1}^{3} P_i(\mu_i - \mu_0)(\mu_i - \mu_0)^T$ (Between-Class Scatter Matrix). Τέλος υπολογίζουμε τον πίνακα $Sw^{-1}Sb$ στον οποίο εφαρμόζουμε eigenvalue decomposition. Ταξινομούμε τις ιδιοτιμές με φθίνουσα και παίρνουμε τις $NewDim = 2$ πρώτες καθώς και τα ιδιοδιανύσματα που τους αντιστοιχούν, τα οποία αποτελούν το διάνυσμα προβολής LDA.

d. Χρησιμοποιούμε το διάνυσμα που μόλις λάβαμε για να βρούμε την προβολή των δειγμάτων πάνω σε αυτο. Τα δείγματα που λαμβάνουμε είναι πλέον δισδιάστατα. Παρατηρούμε από το παρακάτω plot, ότι τα χωρίσαμε επιτυχώς με βάση την κλάση τους στον 2-D χώρο, επομένως ο αλγόριθμος LDA λειτούργησε σωστά.

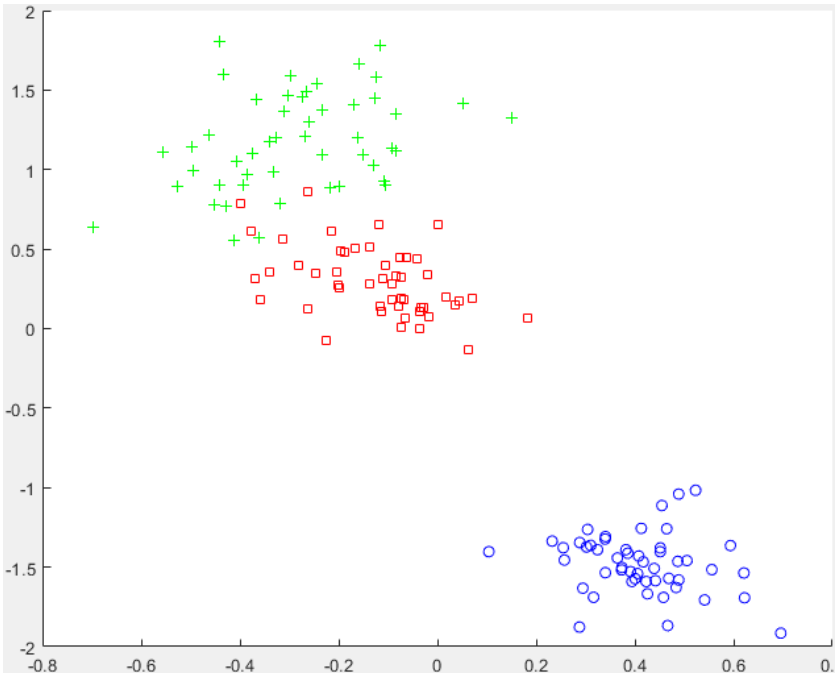

Figure 26: πράσινο: "virginica", μπλε: "setosa", κόκκινο: "versicolor".